
Исследование влияния модульной гибридизации на точность и эффективность трансформеров для долгосрочного прогнозирования временных рядов *

Очкин Н.В.
email@email

Зубарев К.М.
email@email

Аннотация

Задача долгосрочного прогнозирования многомерных временных рядов остается сложной: в реальных данных наблюдается ряд проблемных эффектов - среди них, краткосрочные мотивы (скакки, ступени), крайне долгосрочные и межрядовые зависимости, выраженная нестационарность (сдвиги тренда/уровня, мульти сезонность, гетероскедастичность). В данной работе мы предлагаем расширить слой эмбеддинга в модели Informer [14] компактным двухслойным сверточным блоком с целью повышения эффективности извлечения локальных паттернов, внедрить модуль декомпозиции ряда из Autoformer [12] для явного разделения трендовых и сезонных компонент и заменить механизм ProbSparse на линейное внимание FAVOR+ (Performer [2]) для учёта глобальных зависимостей при низких вычислительных затратах. Эксперименты на стандартных бенчмарках демонстрируют снижение ошибок на длинных горизонтах прогнозирования в ряде настроек. Абляционные исследования указывают на вклад каждого из модулей, хотя эффект не универсален для всех горизонтов. На рассмотренных конфигурациях наблюдается благоприятный компромисс между точностью и затратами времени/памяти.

Keywords LSTF · Long Sequence Time-series Forecasting · Transformer · Informer · Performer · Autoformer

1 Введение

Долгосрочное прогнозирование временных рядов является одной из ключевых задач во многих областях - от энергетики и финансов до транспорта и здравоохранения. Однако реальные многомерные ряды редко обладают простой структурой: среди прочего, они сочетают краткосрочные локальные паттерны, очень длинные и межрядовые зависимости, а также выраженную нестационарность, включая сдвиги тренда, мульти сезонность и гетероскедастичность. Эти свойства затрудняют обучение моделей и ухудшают их способность к экстраполяции на длительных горизонтах.

С момента публикации, архитектура Трансформера [11] завоевала широкое признание. Однако у нее есть несколько серьезных проблем, которые усложняют работу с длинными временными последовательностями (LSTF). Последующие исследования предложили различные методы решения данных и связанных с ними проблем (Informer [14], Autoformer [12], Performer [2]). Тем не менее, существующие архитектуры сталкиваются с рядом ограничений: необходимость одновременного учёта локальных и глобальных закономерностей, высокая чувствительность к нестационарности и ограниченная масштабируемость по длине входной последовательности.

* Исходный код, конфигурации и скрипты обучения доступны: <https://github.com/namenick91/Convformer>

В данной работе мы предлагаем архитектуру, которая объединяет три взаимодополняющих индуктивных смещения, специально ориентированных на решение этих вызовов: **(i)** расширенный сверточный входной блок, способный эффективно кодировать краткосрочные локальные паттерны (скакки, ступени, импульсные всплески). Такой модуль выполняет роль фильтра низкого уровня и одновременно стабилизирует статистики входных данных, что повышает устойчивость модели к локальной нестационарности; **(ii)** механизм внимания FAVOR+ (Performer [2]), обеспечивающий линейные $O(Lr)$ затраты времени и памяти; параметр ранга r задаёт настраиваемый компромисс между скоростью и точностью. Это позволяет обрабатывать очень длинные последовательности и улавливать отложенные зависимости без взрыва затрат, что критично для прогнозов на больших горизонтах. **(iii)** явная декомпозиция ряда в стиле Autoformer [12] после каждого блока self-attention: низкочастотный тренд выводится через остаточные соединения, а очищенный от тренда стационаризованный остаток подаётся в механизм внимания. Такой приём снижает влияние сдвигов уровня и многосезонности, улучшая обобщающую способность модели.

Такая композиция локальной фильтрации, глобального внимания и явной декомпозиции улучшает точность прогнозирования на длинных горизонтах, ускоряет и стабилизирует оптимизацию, а также снижает затраты памяти по сравнению с базовыми трансформер-подходами. Основной вклад данной работы можно резюмировать следующим образом:

- Вводим расширенный сверточный входной блок для кодирования краткосрочных мотивов и стабилизации статистик нестационарных входов.
- Для моделирования глобальных связей применяем FAVOR+ внимание с линейными затратами по времени и памяти, что обеспечивает масштабируемое и не зависящее от распределения моделирование глобальных зависимостей;
- Встраиваем Autoformer-подобную [12] декомпозицию после каждого блока self-attention, которая пропускает низкочастотный тренд по остаточным соединениям и передаёт более стационаризованный поток данных в механизм внимания.
- Эксперименты на стандартных бенчмарках демонстрируют устойчивое снижение ошибок на длительных горизонтах прогнозирования; аблационные исследования подтверждают вклад каждого модуля, а анализ масштабируемости показывает благоприятный баланс между точностью и вычислительными затратами.

2 Методология

Повышение эффективности извлечения локальных паттернов Для усиления способности модели к распознаванию краткосрочных закономерностей мы предлагаем заменить стандартный механизм представления значений (TokenEmbedding) на сверточный блок ConvStem. Данный блок сочетает проекцию входных признаков через точечную свёртку с последующими операциями широкой и глубинной свёрток, дополненных нормализацией и нелинейностью. Такое построение позволяет модели фиксировать повторяющиеся локальные мотивы и вариации формы сигналов непосредственно на этапе встраивания, ещё до применения механизмов внимания. В результате глобальное внимание может быть сфокусировано преимущественно на долговременных зависимостях, тогда как локальная динамика эффективно извлекается специализированным сверточным модулем.

Масштабируемое моделирование глобальных зависимостей В качестве механизма внимания предлагаются использовать FAVOR+ (Performer [2]) вместо ProbSparse (оригинально применяемого в Informer [14]). Подобно тому, как в оригинальном Informer [14] механизм FullAttention [11] был заменен на ProbSparse исключительно для вычисления self-attention (механизм самовнимания) в слоях кодировщика и декодера, в нашей модификации ProbSparse заменяется на FAVOR+ в тех же местах, тогда как cross-attention останется реализованным через полное внимание (FullAttention). Данную замену мы мотивируем тем, что FAVOR+ обеспечивает несмешённую аппроксимацию softmax-ядра с линейной по времени и памяти сложностью [2], что гарантирует предсказуемую и масштабируемую работу на очень длинных последовательностях в условиях ограниченных ресурсов GPU. При этом точность аппроксимации управляется числом случайных признаков r : при меньших значениях достигается высокая скорость, при больших - более точное восстановление распределения внимания. Такая настраиваемость делает механизм универсальным инструментом, позволяющим варьировать баланс

между эффективностью и качеством. Кроме того, отказ от ручной выборки top- u запросов позволяет модели учитывать любые глобальные зависимости, а не только наиболее сильные периодические, что критично для учёта непериодичных скачков в реальных временных рядах.

Явное разделение тренда и сезонности Чтобы явно разделить тренд и сезонную компоненту, мы интегрировали механизм декомпозиции временных рядов, заимствованный из архитектуры Autoformer [12]. После каждого блока self-attention скрытое представление разлагается на два канала: низкочастотный тренд и остаточную компоненту, содержащую более стационарные сезонные и случайные колебания. Тренд передаётся по остаточному пути, обеспечивая стабильность прогнозов при сдвигах уровня, тогда как внимание применяется к сезонной компоненте, где наиболее выражены периодические и локальные закономерности. Такая стратегия снижает вариативность обучения, повышает способность к экстраполяции за пределами обучающего диапазона и улучшает интерпретируемость результатов за счёт явного выделения трендовой и сезонной составляющих.

Схема механизма декомпозиции ряда [12]

Input: X

- (1) [SeriesDecomp] \rightarrow Trend, Seasonal
Trend = AvgPool(Padding(X))
where Seasonal = $X - \text{Trend}$
 - (2) [self-attention mechanism] on Seasonal
 \rightarrow Seasonal' (+ residual connection, normalization, etc.)
 - (3) [Feed-Forward] on Seasonal' \rightarrow $\widetilde{\text{Seasonal}}$
 - (4) Re-compose $X = \widetilde{\text{Seasonal}} + \text{Trend}$
-

В итоге архитектура объединяет сильные стороны трёх подходов: локальное кодирование паттернов через ConvStem, линейное глобальное внимание FAVOR+ и явную декомпозицию ряда из Autoformer [12], сохраняя при этом полную совместимость с остальными гиперпараметрами оригинального Informer [14].

3 Эксперимент

Датасет Ниже приводится описание набора данных экспериментов: *ETT* [14] датасет содержит информацию, собранную с электрических трансформаторов, включая нагрузку и температуру масла, которые регистрировались каждые 15 минут в период с июля 2016 года по июль 2018 года.

Детали реализации Обучение проводилось с использованием функции потерь MSE (L2) и оптимизатора Adam [8] с начальной скоростью обучения 10^{-4} . Размер батча - 32. Процесс обучения досрочно останавливается в пределах 10 эпох. Результаты экспериментов были получены в ходе усреднения по трем отдельным запускам, реализованы в PyTorch [10] и проводились на одной графической карте NVIDIA GTX 1660 SUPER с 6 ГБ видеопамяти. Архитектура модели включает 2 слоя энкодера и 1 слой декодера. Полный перечень гиперпараметров и конфигураций приведён в репозитории: <https://github.com/namenick91/Convformer>

3.1 Абляционные исследования

ConvStem вместо TokenEmbedding Сравнивалась эффективность оригинальной модели Informer [14] и её модификации с расширенным слоем эмбеддинга 2.

Встраивание компактного сверточного блока на вход приводит к заметному улучшению качества на коротких (24-48) и особенно длинных горизонтах (336), при этом затраты по времени остаются сопоставимыми. Однако на отдельных горизонтах (например, 168) Informer [14] сохраняет преимущество. Это подтверждает, что сверточная фильтрация локальных паттернов в среднем повышает устойчивость к краткосрочной нестационарности, хотя её вклад не универсален.

Horizon	Conformer			Informer			Performer			Autoformer			
	MSE	MAE	t	MSE	MAE	t	MSE	MAE	t	MSE	MAE	t	
ETTh1	24	0.388	0.428	3m50s/4s	0.524	0.527	2m5s/3s	0.598	0.570	2m50s/4s	0.401	0.425	3m58s/7s
	48	0.435	0.451	3m55s/4s	0.631	0.601	2m24s/4s	0.765	0.673	2m35s/4s	0.430	0.445	4m43s/7s
	168	0.435	0.459	8m39s/6s	0.825	0.705	3m14s/5s	0.918	0.768	3m42s/6s	0.478	0.473	6m45s/11s
	336	0.469	0.490	7m55s/8s	1.310	0.937	9m19s/6s	1.024	0.823	5m36s/7s	0.516	0.497	10m19s/17s
	720	0.510	0.528	12m51s/10s	1.205	0.879	14m36s/9s	1.107	0.843	14m9s/9s	-	-	-
ETTh2	24	0.248	0.345	2m38s/4s	1.284	0.891	1m58s/3s	1.296	0.907	2m49s/4s	0.290	0.365	4m7s/6s
	48	0.298	0.373	2m49s/5s	1.559	1.008	1m58s/4s	1.568	1.008	2m35s/4s	0.324	0.382	3m31s/6s
	168	0.539	0.509	4m6s/6s	7.587	2.335	2m49s/5s	8.487	2.569	3m40s/6s	0.451	0.456	5m15s/9s
	336	0.684	0.600	7m9s/8s	4.369	1.773	4m19s/7s	8.158	2.456	6m16s/7s	0.478	0.480	7m3s/13s
	720	0.662	0.595	13m1s/11s	2.977	1.467	6m1s/9s	3.707	1.640	7m39s/9s	-	-	-

Таблица 1: Результаты многомерных предсказаний на 2 датасетах ETT с горизонтами предсказаний: { 24, 48, 168, 336, 720 }. Мы фиксируем входную длину последовательностей у моделей как 96. Символ “-” обозначает выход за пределы памяти (OOM). Время указано как train/inference. Полный бенчмарк см. в табл. ???. Примеры визуализации приведены на рис. B.1.

Horizon	Informer			ConvStem		
	MSE	MAE	t	MSE	MAE	t
24	0.524	0.527	2m5s/3s	0.469	0.480	2m11s/4s
48	0.631	0.601	2m24s/4s	0.587	0.558	2m23s/4s
168	0.825	0.705	3m14s/5s	0.861	0.733	3m34s/5s
336	1.310	0.937	9m19s/6s	1.094	0.843	7m22s/7s
720	1.205	0.879	14m36s/9s	1.261	0.913	9m58s/9s

Таблица 2: Результаты многомерных предсказаний на датасете ETTh1 с горизонтами предсказаний: { 24, 48, 168, 336, 720 }. Входная длина последовательности фиксирована: 96. Время указано как train/inference. Примеры визуализации приведены в табл. 6.

ProbSparse → FAVOR+ Сравнивалась эффективность Informer [14] с исходным механизмом ProbSparse и модифицированной версии, в которой ProbSparse заменён на FAVOR+ (Performer [2]).

Horizon	Informer			Informer w/ FAVOR+		
	MSE	MAE	t	MSE	MAE	t
24	0.524	0.527	2m5s/3s	0.494	0.505	2m30s/4s
48	0.631	0.601	2m24s/4s	0.710	0.640	2m20s/4s
168	0.825	0.705	3m14s/5s	0.864	0.746	3m24s/5s
336	1.310	0.937	9m19s/6s	1.088	0.846	6m22s/7s
720	1.205	0.879	14m36s/9s	1.065	0.831	9m54s/9s

Таблица 3: Результаты многомерных предсказаний на датасете ETTh1 с горизонтами предсказаний: { 24, 48, 168, 336, 720 }. Входная длина последовательности фиксирована: 96. Время указано как train/inference. Примеры визуализации приведены в табл. 7.

Линейное внимание обеспечивает выигрыш по качеству на длинных горизонтах (336, 720) при сопоставимых или меньших вычислительных затратах, в то время как на коротких горизонтах улучшение выражено слабее или отсутствует. Таким образом, FAVOR+ [2] даёт наибольший эффект именно в режимах, где глобальные зависимости становятся критичными, подтверждая его ценность для масштабируемого долгосрочного прогнозирования.

Informer с модулем декомпозиции Сравнивалась эффективность оригинальной модели Informer [14] и модификации, дополненной механизмом декомпозиции ряда из Autoformer [12].

Horizon	Informer			Informer w/ s.decomp		
	MSE	MAE	<i>t</i>	MSE	MAE	<i>t</i>
ETTh1	24	0.524	0.527	2m5s/3s	0.478	0.494
	48	0.631	0.601	2m24s/4s	0.561	0.547
	168	0.825	0.705	3m14s/5s	0.649	0.597
	336	1.310	0.937	9m19s/6s	0.952	0.748
	720	1.205	0.879	14m36s/9s	1.059	0.775

Таблица 4: Результаты многомерных предсказаний на датасете ETTh1 с горизонтами предсказаний: { 24, 48, 168, 336, 720 }. Входная длина последовательности фиксирована: 96. Время указано как train/inference. Примеры визуализации приведены в табл. 8.

Встраивание операции разделения на тренд и остаток после каждого блока self-attention приводит к систематическому снижению ошибок на всех горизонтах ETTh1, хотя ценой становится рост времени обучения и инференса (inference). Это подтверждает гипотезу о том, что явная стабилизация нестационарности улучшает обобщающую способность модели, особенно при наличии сдвигов уровня и мульти сезонности.

4 Заключение

Предложенная комбинация ConvStem + FAVOR+ + Autoformer-подобная декомпозиция демонстрирует улучшение качества на длинных горизонтах при сопоставимых вычислительных затратах на рассматриваемых настройках. Абляционные исследования подтверждают вклад модулей на большинстве горизонтов: ConvStem - выделение локальных мотивов; FAVOR+ - масштабируемые дальние зависимости; декомпозиция - устойчивость к тренду/сезонности. На ETT наибольшие выигрыши достигаются при длительных горизонтах (336-720), тогда как на средних горизонтах Autoformer остается сопоставимым.

При этом исследование имеет ряд ограничений: в качестве бенчмарка был рассмотрен один набор данных (ETT), cross-attention сохраняет квадратичную сложность, чувствительность MAPE/MSPE к масштабам признаков, отсутствие оценки неопределенности. Перспективными направлениями являются линеаризация cross-attention, адаптивный выбор ранга r в FAVOR+, расширение набора датасетов, включение калибровки и методов, устойчивых к дрейфу распределений.

Список использованных источников

- [1] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. Neural machine translation by jointly learning to align and translate. In International Conference on Learning Representations (ICLR), 2015.
- [2] Krzysztof Choromanski, Valentin Likhoshesterov, David Dohan, Xingyou Song, Alex Gane, Tamas Sarlos, Peter Hawkins, Jared Davis, Afroz Mohiuddin, Łukasz Kaiser, David Belanger, Lucy Colwell, and Adrian Weller. Rethinking attention with performers. In Proceedings of the International Conference on Learning Representations (ICLR), 2020. arXiv:2009.14794.
- [3] Gregory C. Reinsel George E. P. Box, Gwilym M. Jenkins and Greta M. Ljung. Time Series Analysis: Forecasting and Control. Wiley, fifth edition edition, 2015.
- [4] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep Learning. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [5] James D. Hamilton. Time Series Analysis. Princeton University Press, 1994.
- [6] Rob J. Hyndman and George Athanasopoulos. Forecasting: principles and practice. OTexts, 2013.
- [7] Brockwell P. J. and Davis R. A. Introduction to Time Series and Forecasting. Springer, third edition edition, 2016.

- [8] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In International Conference on Learning Representations (ICLR), 2015.
- [9] Kevin P. Murphy. Probabilistic Machine Learning: An introduction. MIT Press, 2022.
- [10] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zach DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and Soumith Chintala. Pytorch: An imperative style, high-performance deep learning library. In Advances in Neural Information Processing Systems (NeurIPS), 2019.
- [11] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In Advances in Neural Information Processing Systems (NeurIPS), volume 30, 2017.
- [12] Haixu Wu, Jiehui Xu, Jianmin Wang, and Mingsheng Long. Autoformer: Decomposition transformers with Auto-Correlation for long-term series forecasting. In Advances in Neural Information Processing Systems, 2021.
- [13] Haoyi Zhou, Jianxin Li, Shanghang Zhang, Shuai Zhang, Mengyi Yan, and Hui Xiong. Expanding the prediction capacity in long sequence time-series forecasting. *Artificial Intelligence*, 318:103886, 2023.
- [14] Haoyi Zhou, Shanghang Zhang, Jieqi Peng, Shuai Zhang, Jianxin Li, Hui Xiong, and Wancai Zhang. Informer: Beyond efficient transformer for long sequence time-series forecasting. In The Thirty-Fifth AAAI Conference on Artificial Intelligence, AAAI 2021, Virtual Conference, volume 35, pages 11106–11115. AAAI Press, 2021.

A Полный бенчмарк

Models		Conformer						Informer					
Metrics		MSE	MAE	RMSE	MAPE	MSPE	<i>t</i>	MSE	MAE	RMSE	MAPE	MSPE	<i>t</i>
ETH1	24	0.388	0.428	0.622	11.030	50292.405	3m50s/4s	0.524	0.527	0.724	11.117	43860.164	2m5s/3s
	48	0.435	0.451	0.660	10.864	49359.185	3m55s/4s	0.631	0.601	0.794	11.973	50739.564	2m24s/4s
	168	0.435	0.459	0.659	11.585	48605.939	8m39s/6s	0.825	0.705	0.908	9.711	31104.102	3m14s/5s
	336	0.469	0.490	0.685	12.928	62006.074	7m55s/8s	1.310	0.937	1.143	17.267	108984.891	9m19s/6s
	720	0.510	0.528	0.714	12.617	56880.186	12m51s/10s	1.205	0.879	1.098	17.282	111811.141	14m36s/9s
ETH2	24	0.248	0.345	0.498	1.511	282.651	2m38s/4s	1.284	0.891	1.133	8.751	4080.943	1m58s/3s
	48	0.298	0.373	0.546	1.569	244.634	2m49s/5s	1.559	1.008	1.247	9.655	4751.785	1m58s/4s
	168	0.539	0.509	0.733	2.148	315.627	4m6s/6s	7.587	2.335	2.754	13.709	9135.792	2m49s/5s
	336	0.684	0.600	0.826	2.552	646.271	7m9s/8s	4.369	1.773	2.088	10.857	8606.445	4m19s/7s
	720	0.662	0.595	0.811	2.721	630.013	13m1s/11s	2.977	1.467	1.725	11.613	8735.043	6m1s/9s
ECL	24	0.161	0.282	0.401	2.733	184480.104	14m17s/10s	0.253	0.356	0.503	3.467	273059.568	9m21s/9s
	48	0.176	0.293	0.419	2.954	279521.807	15m36s/11s	0.273	0.366	0.522	3.671	727175.448	10m27s/10s
	168	0.198	0.312	0.445	3.226	426142.281	23m6s/17s	0.288	0.381	0.537	3.737	490357.865	15m11s/26s
	336	0.217	0.330	0.466	3.124	284631.927	33m29s/44s	0.315	0.404	0.561	4.071	782375.385	23m50s/51s
	720	—	—	—	—	—	—	—	—	—	—	—	—
Exchange	24	0.078	0.213	0.279	1.531	979.048	2m14s/2s	0.420	0.523	0.648	2.114	1814.837	1m11s/2s
	48	0.118	0.257	0.344	1.771	1100.554	2m17s/2s	0.584	0.614	0.764	2.369	2133.454	1m17s/2s
	168	0.493	0.501	0.701	3.045	1983.890	3m25s/3s	1.142	0.873	1.068	2.758	2029.441	2m0s/2s
	336	0.621	0.581	0.785	4.414	4206.705	3m6s/4s	1.767	1.061	1.329	3.697	4412.673	2m51s/3s
	720	0.591	0.597	0.765	4.701	7660.512	4m30s/4s	2.834	1.404	1.682	3.629	2881.192	2m47s/3s
Illness	24	3.021	1.158	1.738	3.858	790.506	22.5s/0.57s	5.451	1.615	2.335	2.771	524.814	12.5s/0.46s
	36	2.962	1.147	1.721	3.951	874.860	17.3s/0.57s	5.059	1.541	2.249	2.300	329.746	16.9s/0.49s
	48	3.040	1.145	1.744	3.583	940.316	25.9s/0.57s	5.028	1.536	2.242	2.129	214.023	15.7s/0.49s
	60	2.921	1.113	1.709	2.924	707.285	27.9s/0.57s	5.340	1.578	2.310	1.988	226.419	19.6s/0.51s
	720	0.533	0.341	0.730	4.028	460139.0	3m24s/9s	0.705	0.398	0.839	4.297	286806.7	2m21s/12s
Traffic	24	0.556	0.352	0.745	4.079	417170.1	3m47s/10s	0.685	0.380	0.828	4.254	406973.7	2m34s/24s
	48	0.597	0.378	0.773	4.267	402130.7	5m37s/46s	0.740	0.404	0.860	4.651	732249.998	3m38s/64s
	168	0.620	0.386	0.787	4.540	534398.4	8m1s/2m43s	0.770	0.420	0.877	4.801	868452.4	5m20s/8m54s
	336	—	—	—	—	—	—	—	—	—	—	—	—
	720	—	—	—	—	—	—	—	—	—	—	—	—
Count ↑		91						33					
Models		Performer						Autoformer					
Metrics		MSE	MAE	RMSE	MAPE	MSPE	<i>t</i>	MSE	MAE	RMSE	MAPE	MSPE	<i>t</i>
ETH1	24	0.598	0.570	0.773	13.036	59454.181	2m50s/4s	0.401	0.425	0.633	10.876	47465.651	3m58s/7s
	48	0.765	0.673	0.873	9.637	27418.091	2m35s/4s	0.430	0.445	0.656	10.304	46080.775	4m43s/7s
	168	0.918	0.768	0.957	9.107	22036.375	3m42s/6s	0.478	0.473	0.691	12.045	54136.419	6m45s/11s
	336	1.024	0.823	1.011	11.928	42467.367	5m36s/7s	0.516	0.497	0.717	12.388	57259.240	10m19s/17s
	720	1.107	0.843	1.052	20.032	149892.094	14m9s/9s	—	—	—	—	—	—
ETH2	24	0.124	0.204	0.353	5.620	1.845e6	10m59s/16s	0.155	0.237	0.393	5.983	2.583e6	7m10s/11s
	48	0.167	0.248	0.408	6.509	2.939e6	18m49s/17s	0.240	0.323	0.488	7.647	3.596e6	7m51s/12s
	168	0.271	0.347	0.521	7.996	4.759e6	23m48s/22s	0.490	0.497	0.700	10.539	8.437e6	12m15s/17s
	336	0.425	0.460	0.652	9.491	7.897e6	37m21s/31s	0.626	0.554	0.791	12.869	1.394e7	20m20s/23s
	720	0.652	0.596	0.807	11.201	1.058e7	51m7s/47s	0.912	0.687	0.955	13.073	1.569e7	51m36s/35s
Count ↑		91						33					
Models		Performer						Autoformer					
Metrics		MSE	MAE	RMSE	MAPE	MSPE	<i>t</i>	MSE	MAE	RMSE	MAPE	MSPE	<i>t</i>
ECL	24	0.265	0.371	0.514	3.660	329397.198	11m32s/9s	0.170	0.290	0.412	2.891	328888.820	12m30s/12s
	48	0.276	0.373	0.525	3.564	344570.990	12m29s/10s	0.182	0.298	0.427	2.992	340114.255	13m22s/13s
	168	0.286	0.383	0.535	3.485	218124.938	18m47s/15s	0.220	0.329	0.469	3.435	813512.312	17m10s/22s
	336	0.301	0.394	0.548	3.574	157188.534	30m16s/1m4s	0.261	0.359	0.510	3.663	826948.354	24m35s/52s
	720	—	—	—	—	—	—	—	—	—	—	—	—
Exchange	24	0.272	0.418	0.521	1.484	773.929	1m59s/2s	0.065	0.185	0.254	1.227	811.182	3m40s/3s
	48	0.437	0.520	0.661	1.521	718.430	2m37s/2s	0.119	0.253	0.344	1.505	1148.252	2m54s/3s
	168	1.352	0.904	1.162	2.562	1232.125	3m18s/3s	0.267	0.378	0.516	2.318	2909.300	2m38s/5s
	336	1.892	1.071	1.373	3.455	2998.726	5m23s/23s	0.468	0.508	0.684	3.485	4855.862	3m45s/6s
	720	2.783	1.405	1.668	3.446	2413.859	3m58s/4s	—	—	—	—	—	—
Illness	24	5.130	1.566	2.265	2.770	528.412	21.3s/0.55s	3.645	1.353	1.909	5.318	971.594	20.5s/0.59s
	36	4.904	1.502	2.214	2.115	210.091	18.7s/0.53s	3.511	1.300	1.873	5.143	1202.658	20.5s/0.58s
	48	4.733	1.445	2.175	1.741	85.232	22.0s/0.53s	3.149	1.197	1.774	4.515	1257.991	27.8s/0.61s
	60	5.212	1.533	2.283	1.913	164.459	25.7s/0.55s	2.905	1.152	1.704	3.834	1131.912	27.6s/0.61s
	720	—	—	—	—	—	—	—	—	—	—	—	—
Traffic	24	0.667	0.382	0.817	4.293	409754.1	2m54s/8s	0.587	0.388	0.766	4.495	448683.9	3m25s/10s
	48	0.666	0.373	0.816	3.975	263040.9	3m12s/10s	0.606	0.385	0.778	4.161	283556.4	3m50s/12s
	168	0.669	0.368	0.818	4.016	342463.6	4m40s/56s	—	—	—	—	—	—
	336	0.678	0.372	0.824	4.015	334032.96	6m35s/5m7s	—	—	—	—	—	—
	720	0.925	0.701	0.962	11.919	1.230e7	75m56s/41s	—	—	—	—	—	—
Count ↑		30						34					

Таблица 5: указать, что в некоторых датасетах начальный инпут разный и количество предсказываемых фичей

B Дополнение к основным результатам

B.1 Визуализация аблационных исследований

Для оценки предсказаний различных моделей приводится визуализация результатов прогнозирования на тестовой выборке набора данных ETTh1 в рамках аблационных исследований, что позволяет провести качественное сравнение.

Таблица 6: Примеры прогнозирования из набора данных ETTh1 в ходе аблационных исследований *ConvStem вместо TokenEmbedding* (см. раздел 3.1) в настройках `input=96-predict-horizon`. Синие линии - истинные значения, оранжевые линии - предсказания модели, зеленые - входные данные длиной 96.




Таблица 7: Примеры прогнозирования из набора данных ETTh1 в ходе аблационных исследований *ProbSparse → FAVOR+* (см. раздел 3.1) в настройках `input=96-predict-horizon`.





Таблица 8: Примеры прогнозирования из набора данных ETTh1 в ходе абляционных исследований *Informer* с модулем декомпозиции (см. раздел 3.1) в настройках `input-96-predict-horizon`.



B.2 Визуализация основных результатов




Рис. B.1: Примеры прогнозирования из набора данных ETTh1 в настройках `input-96-predict-336`.